

Дисперсионный анализ (ДА) = ANOVA (analysis of variance)

Примеры задач, которые решает ANOVA:

- Оценка средней успеваемости студентов после использования различных методов обучения (например, онлайн, очное, смешанное);
- Оценку влияния различных удобрений на урожайность сельскохозяйственных культур;
- Анализ эффективности рекламных кампаний, проведенных в разных регионах;
- Изучение влияния стресса на когнитивные способности у разных групп людей;
- Оценка эффективности нового лекарства по сравнению с плацебо и стандартным препаратом.

Что общего у этих задач ?

В этих экспериментах и исследованиях возникает необходимость сравнить несколько групп между собой. Например:

Группы студентов, обучающихся онлайн, очно и смешано;

Растения, выращенные с помощью азотных, калийных и комплексных удобрений;

Сильный, средний и сильный стресс и т.д

Переменная, которая будет разделять наших испытуемых или наблюдения на группы (номинативная переменная с нескольким градациями) называется **независимой переменной (фактор)**. Значением этой переменной мы можем управлять (задавать, контролировать).


Пример факторов — тип обучения, вид удобрения, уровень стресса.

Количественная переменная, по степени выраженности, которой мы сравниваем группы, называется **зависимая переменная (отклик)**. Например, баллы тестирования студентов, количество плодов, количество решенных примеров и т.д.

Выделяют **однофакторный и многофакторный** дисперсионный анализ.

1.1 Однофакторный дисперсионный анализ

№ экс-та Уровни фактора	Один фактор X	Отклики объекта исследования при фиксированном уровне фактора				СВ	Групп. средняя	Групп. дисперсия
				
1	Метод 1	50	85	...	30	Y_1	\bar{y}_1	s_1^2
2	Метод 2	90	75	...	70	Y_2	\bar{y}_2	s_2^2
3	Метод 3	80	45		65	Y_3		
4	Метод 4	40	60	...	55	Y_4	\bar{y}_k	s_k^2




Рассмотрим для примера задачу.

Чтобы выяснить, как лучше преподавать статистику, преподаватели разбили всех студентов на 4 группы по 15 человек в каждой. В каждой группе использовалась различная методика преподавания. Т.е. фактор — метод преподавания. В конце года каждая группа написала итоговую работу. Отклик — балл за работу.

Влияет ли методика преподавания на усвоение материала?

Надо придумать какое-то математическое правила, чтобы проверить это утверждение (гипотезу)

1.1 Идея дисперсионного анализа



Влияет ли методика преподавания понимание материала?

Разброс (дисперсия) баллов возникает по двум причинам:
из-за разброса внутри группы и
из-за разброса между группами.

Почему возникает разброс внутри группы Y_i , обучающейся по одной методике? Точно не из-за методики, а по каким-то другим случайным факторам.

Почему возникает разброс между группами? Из-за разной методики преподавания.

Идея дисперсного анализа состоит в сравнении межгрупповой дисперсии («факторной дисперсии») S_x , порождаемой воздействием фактора, и внутригрупповой дисперсии («остаточной дисперсии») S_o , обусловленной случайными причинами.

⇒ Если различие **незначимо**, то влияние несущественно.

!!! Также можно утверждать, что в этом случае средние различных групп значимо не различаются, т. е.

$$m_1 = m_2 = m_3 = m_4$$

⇒ Если различие **значимо**, то влияние существенно.

!!! В этом случае хотя бы одна пара средних различается значимо.

Классические методы дисперсионного анализа основываются на следующих предпосылках:


- распределение исходных случайных величин нормально;
- дисперсии экспериментальных данных одинаковы для всех условий эксперимента.

1.1 Как определяются факторная и остаточные дисперсии

№ экс-та Уровни фактора	Один фактор X	Отклики объекта исследования при фиксированном уровне фактора				СВ	Групп. средняя	Групп. дисперсия
		y_{11}	y_{12}	...	y_{1n}			
1	x_1	y_{11}	y_{12}	...	y_{1n}	Y_1	\bar{y}_1	s_1^2
2	x_2	y_{21}	y_{22}	...	y_{2n}	Y_2	\bar{y}_2	s_2^2
...								
k	x_k	y_{k1}	y_{k2}	...	y_{kn}	Y_k	\bar{y}_k	s_k^2

$$\bar{y}_i = \frac{1}{n} \sum_{j=1}^n y_{ij}$$

$$\bar{y} = \frac{1}{k} \sum_{i=1}^k \bar{y}_i$$



$$S^2 = \frac{1}{kn - 1} \sum_{i=1}^k \sum_{j=1}^n (y_{ij} - \bar{y})^2$$

Общая выборочная дисперсия

$$Q = Q_O + Q_X$$

$$S^2(nk - 1) = S_O^2(n - 1)k + S_X^2(k - 1)$$

$$s_i^2 = \frac{1}{n - 1} \sum_{j=1}^n (y_{ij} - \bar{y}_i)^2$$

$$S_X^2 = \frac{n}{k - 1} \sum_{i=1}^k (\bar{y}_i - \bar{y})^2$$

Факторная дисперсия,
характеризует изменение средних,
связанное с влиянием фактора
оценка дисперсии групповых средних

$$S_O^2 = \frac{1}{k} \sum_{i=1}^k s_i^2 = \frac{1}{k(n - 1)} \sum_{i=1}^k \sum_{j=1}^n (y_{ij} - \bar{y}_i)^2$$

Остаточная дисперсия,
характеризует рассеяние вне влияния фактора
среднеарифметическое для оценок дисперсий

1.1 Алгоритм проведения однофакторного дисперсионного анализа

- 1 Проверка гипотезы о нормальном распределении исходных случайных величин $Y_i, i = 1...n$
Критерии Колмогорова и Хи-квадрат.
- 2 Дисперсия случайной величины $D[Y]$ является характеристикой объекта исследования и определяется только его природой. Поэтому значение величины $D[Y]$ одинаково для всех случайных величин во всех строках таблицы данных (**однородности дисперсий или воспроизводимость дисперсий**).

Т.е. внутри групп дисперсия возникает за счет каких-то внешних факторов. Например, количество часов сна перед контрольной. Требуется, чтобы эти факторы были постоянными в случае перехода от одной группы к другой. Т.е. фактор сна действует на всех студентов одинаково, не зависимо от группы. В этом случае внутригрупповые дисперсии должны быть равны (не отличаться значимо).

$$H_0: \sigma_1 = \sigma_2 = \dots = \sigma_k \quad \text{Тест Левена. Изучить самостоятельно!}$$

- 3 Влияние фактора проверяется проверкой гипотезы о значимости статистического критерия:
 $H_0: M[Y_1] = M[Y_2] = \dots = M[Y_k]$ с уровнем значимости α

$$Z = \frac{S_X^2}{S_O^2} \in F(k - 1, k(n - 1))$$

Если $Z > Z_{KP} = F_\alpha^{-1}(k - 1, k(n - 1))$, то влияние фактора незначимо

Пример 1: Произведено по четыре испытания на каждом из трех уровней фактора X . Предполагается, что выборки извлечены из нормальных совокупностей с одинаковыми дисперсиями. Результаты испытаний приведены в таблице:

№ эксп-та Уровни фактора	Один фактор X	Отклики объекта исследования при фиксированном уровне фактора				СВ	Групп. средняя \bar{x}_i	Групп. дисперсия s_i^2
		38	36	35	31			
1	x_1	38	36	35	31	Y_1	35	26/3
2	x_2	20	24	26	30	Y_2	25	52/3
3	x_3	21	22	31	34	Y_3	27	42

Методом дисперсионного анализа при уровне значимости 0.05 проверить воспроизводимость наблюдений и значимость влияния фактора

Решение: 1) Вычислим критерий Кохрена $G_p = \frac{42}{26/3 + 52/3 + 42} \approx 0.62 < G_T(f = 4 - 1, k = 3, \alpha = 0.05) \approx 0.8$

2) общее среднее: $\bar{y} = \frac{1}{k} \sum_{i=1}^k \bar{y}_i = 29$ Гипотеза о воспроизводимости принимается, наблюдаемое различие связано со случайными факторами

3) найдем факторную дисперсию $S_X^2 = \frac{n}{k-1} \sum_{i=1}^k (\bar{y}_i - \bar{y})^2 = \frac{4}{2} ((35 - 29)^2 + 4^2 + 2^2) = 112$


4) найдем остаточную дисперсию $S_O^2 = \frac{1}{k} \sum_{i=1}^k s_i^2 = \frac{26/3 + 52/3 + 42}{3} = \frac{68}{3}$

5) найдем значение критерия Фишера $Z = \frac{S_A^2}{S_O^2} = \frac{112 \cdot 3}{68} = 4.94$

6) найдем критическое значение критерия Фишера (используем таблицу) $F_{\alpha}^{-1}(k-1, k(n-1)) = F_{0.05}^{-1}(2, 9) = 4.26 = Z_{KP}$

$Z > Z_{KP}$ Гипотеза о незначимости критерия Фишера отклоняется. Критерий значим, следовательно фактор значимо влияет на исследуемый отклик.

1.1 Множественное сравнение в однофакторном дисперсионном анализе



Если $H_0: M[Y_1] = M[Y_2] = \dots = M[Y_k]$ отклоняется с уровнем значимости α , то есть хотя бы одна пара групп, в которой имеется статистически значимое отклонение.

Какая? Для этого можно сравнивать каждую пару $H_0: M[Y_i] = M[Y_j]$, используя тест Стьюдента.

Но нельзя при этом использовать тот же уровень значимости α , т. к. получить значимое различие увеличивается пропорционально количеству групп (*лабораторная*).
Аналог. Если бросать монетку один раз, то выпадание «орла» — 0.5, если подбрасывали монетку 1000 раз, то вероятность выпадание хотя бы одного «орла» стремиться к 1.

Самый простой способ — **поправка Бонферрони** $\alpha_{new} = \alpha / N$, где N — количество пар гипотез.

т. е. если групп 4, то пар $N = 4 (4-1)/2 = 6$

Но поправка Бонферрони сильно занижает уровень, поэтому снижается вероятность выявить статистически значимые различия.

Альтернативный метод — **критерий Тьюки** (разобраться самостоятельно)

Отклик является случайной величиной, т. к. на него влияют неучтенные случайные факторы

№ экс-та	Факторы				Отклики объекта исследования			
	X_1	X_2	...	X_m				
1	x_{11}	x_{12}		x_{1m}	y_{11}	y_{12}	...	y_{1n}
2	x_{21}	x_{22}		x_{2m}	y_{21}	y_{22}	...	y_{2n}
...								
k	x_{k1}	x_{k2}		x_{km}	y_{k1}	y_{k2}	...	y_{kn}

Один уровень
факторов

Эксперименты при
различных уровнях факторов

Наблюдения при фиксированном уровне факторов