

Лабораторная работа

Регрессионный анализ данных

По данным Всемирной организации здравоохранения (ВОЗ), инсульт является второй по значимости причиной смерти в мире, на него приходится около 11% всех смертей. Этот набор данных используется для прогнозирования вероятности инсульта у пациента на основе таких входных параметров, как пол, возраст, различные заболевания и статус курения. Каждая строка в данных содержит релевантную информацию о пациенте.

Информация о переменных:

- 1) **id**: уникальный идентификатор;
- 2) **gender**: «Мужской», «Женский», «Другой»;
- 3) **age**: возраст пациента;
- 4) **hypertension**: 0, если у пациента нет гипертензии, 1, если у пациента есть гипертензия;
- 5) **heart_disease**: 0, если у пациента нет никаких заболеваний сердца, 1, если у пациента есть заболевание сердца;
- 6) **ever_married**: «Нет» или «Да»;
- 7) **work_type**: «Ребенок», «Государственное учреждение», «Никогда не работал», «Негосударственная (частная) компания», «Самозанятый»;
- 8) **Residence_type**: место проживания «Сельское» или «Городское»;
- 9) **avg_glucose_level**: средний уровень глюкозы в крови;
- 10) **bmi**: индекс массы тела;
- 11) **smoking_status**: «ранее курил», «никогда не курил», «курит» или «Неизвестно»*
(«Неизвестно» в smoking_status означает, что информация для этого пациента недоступна);
- 12) **stroke**: 1, если у пациента был инсульт или 0, если нет.

Задание №1. Исследовать влияние возраста человека на (age) на индекс массы тела (bmi).

1.1 Подготовить данные для анализа.

1.2. Сделать визуализацию данных.

1.3. Найти описательные статистики исходных данных. Сделать предварительные выводы о свойствах исходных данных.

1.4. Исследовать закон распределения исходных данных и, при необходимости, преобразование исходных данных к нормальному закону распределения (не обязательно).

1.5. Выявить статистически аномальные значения (выбросы). Принять решение об их исключении.

1.6. Корреляционный анализ - исследовать корреляционную связь между исходными данными;

1.7. С помощью модуля statsmodels.formula.api (as smf) получить результаты для линейной регрессионной модели на основе обычного метода наименьших квадратов (Ordinary Least Squares):

Результат будет представлен в виде таблицы:

OLS Regression Results					
Dep. Variable:		R-squared:			
Model:		Adj. R-squared:			
Method:		F-statistic:			
Date:		Prob (F-statistic):			
Time:		Log-Likelihood:			
No. Observations:		AIC:			
Df Residuals:		BIC:			
Df Model:					
Covariance Type:					
	coef	std err	t	P> t	[0.025 0.975]
Omnibus:			Durbin-Watson:		
Prob(Omnibus):			Jarque-Bera (JB):		
Skew:			Prob(JB):		
Kurtosis:			Cond. No.		

Для выделенных переменных понимать, что они означают, и уметь получать их значения самостоятельно.

1.8. На основе модулей sklearn.preprocessing (понадобится функция PolynomialFeatures) и sklearn.linear_model (понадобится функция LinearRegression) построить полиномиальное уравнение регрессии. Вид модели выбрать самостоятельно.

1.9. Сравнить линейную и полиномиальную модель на основе квадрата отклонения предсказанных результатов от экспериментальных данных.

1.10. Построить график уравнений линейной и полиномиальной регрессии совместно с диаграммой рассеяния.

Задача №2. Выбрать из исходной таблицы любую пару из количественной и категориальной переменной. Провести исследование влияние выбранной количественной переменной на категориальную.

2.1 Подготовить данные.

2.2 Сделать визуализацию.

2.3. Провести разделение данных на обучающие и тестовые. Функция `train_test_split` из модуля `sklearn.model_selection`.

2.4. Определить параметры логистического уравнения регрессии. Для этого удобно воспользоваться модулем `sklearn.linear_model` (функция `LogisticRegression`)

2.5. На основе полученной модели получить предсказания для тестовых данных (см. п. 2.3).

2.6. Построить матрицу ошибок. Можно использовать функцию `confusion_matrix` из модуля `sklearn.metrics`.

2.7. Сделать выводы по полученным результатам.

Форма отчета -устная. Знать теорию по теме «Регрессионный анализ данных».